

APRENDIZAJE NO SUPERVISADO

SIA - TP4 - 2022

TABLA DE CONTENIDOS

1. INTRODUCCIÓN

Introducción al problema y sus soluciones.

2. RED DE KOHONEN

Ejercicio 1
Consideraciones
Conclusiones

3. REGLA DE OJA

Ejercicio 2
Consideraciones
Conclusiones

4. MODELO HOPFIELD

Ejercicio 3
Consideraciones
Conclusiones

INTRODUCCIÓN

- El **aprendizaje no supervisado** es un método de aprendizaje automático en el cual se construyen modelos de predicción cuando la variable respuesta no es una información disponible.
- Se implementaron los siguientes algoritmos para resolver problemas de aprendizaje no supervisado tales como agrupamiento, asociaciones o reducción de dimensionalidad:
 - Red de Kohonen
 - Red neuronal utilizando la regla de Oja
 - Modelo de Hopfield
- Gráficos utilizando **Plotly**.

RED DE KOHONEN



EJERCICIO

Se extrajeron datos económicos, sociales y geográficos de un conjunto de 28 países europeos extraídos de un archivo .csv.

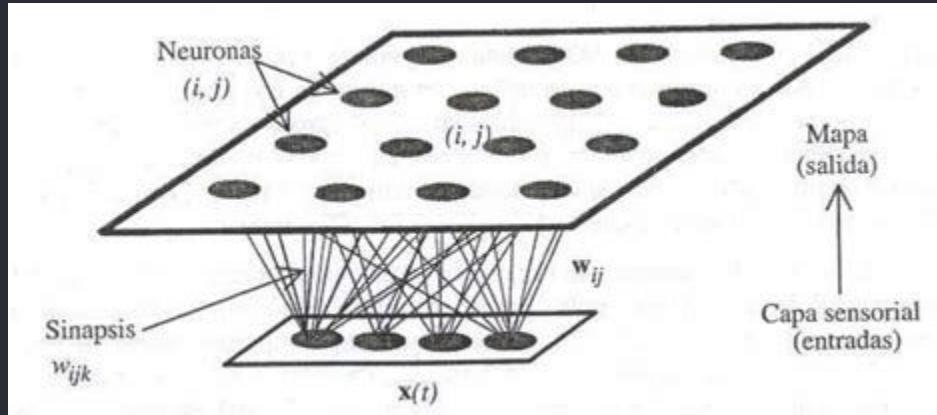
Las variables de este son:

- **Country:** nombre del país.
 - **Área:** área geográfica.
 - **GDP:** producto bruto interno.
 - **Inflation:** inflación anual.
 - **Life.expect:** expectativa de vida media en años.
 - **Military:** nivel militar
 - **Pop.growth:** tasa de crecimiento poblacional.
 - **Unemployment:** tasa de desempleo.

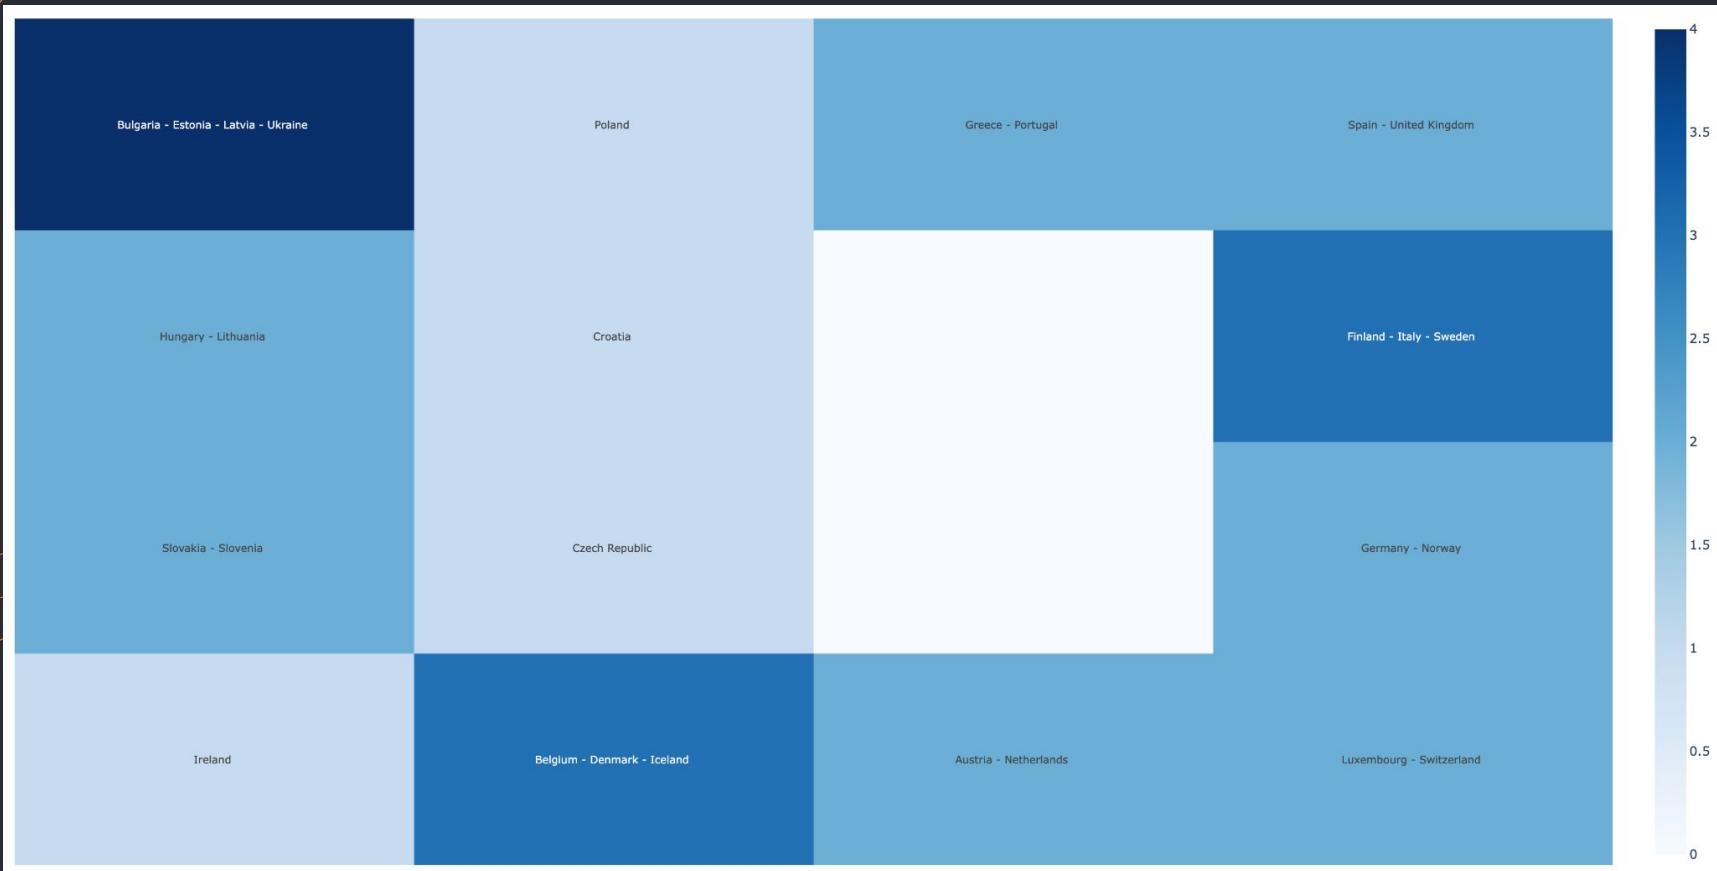


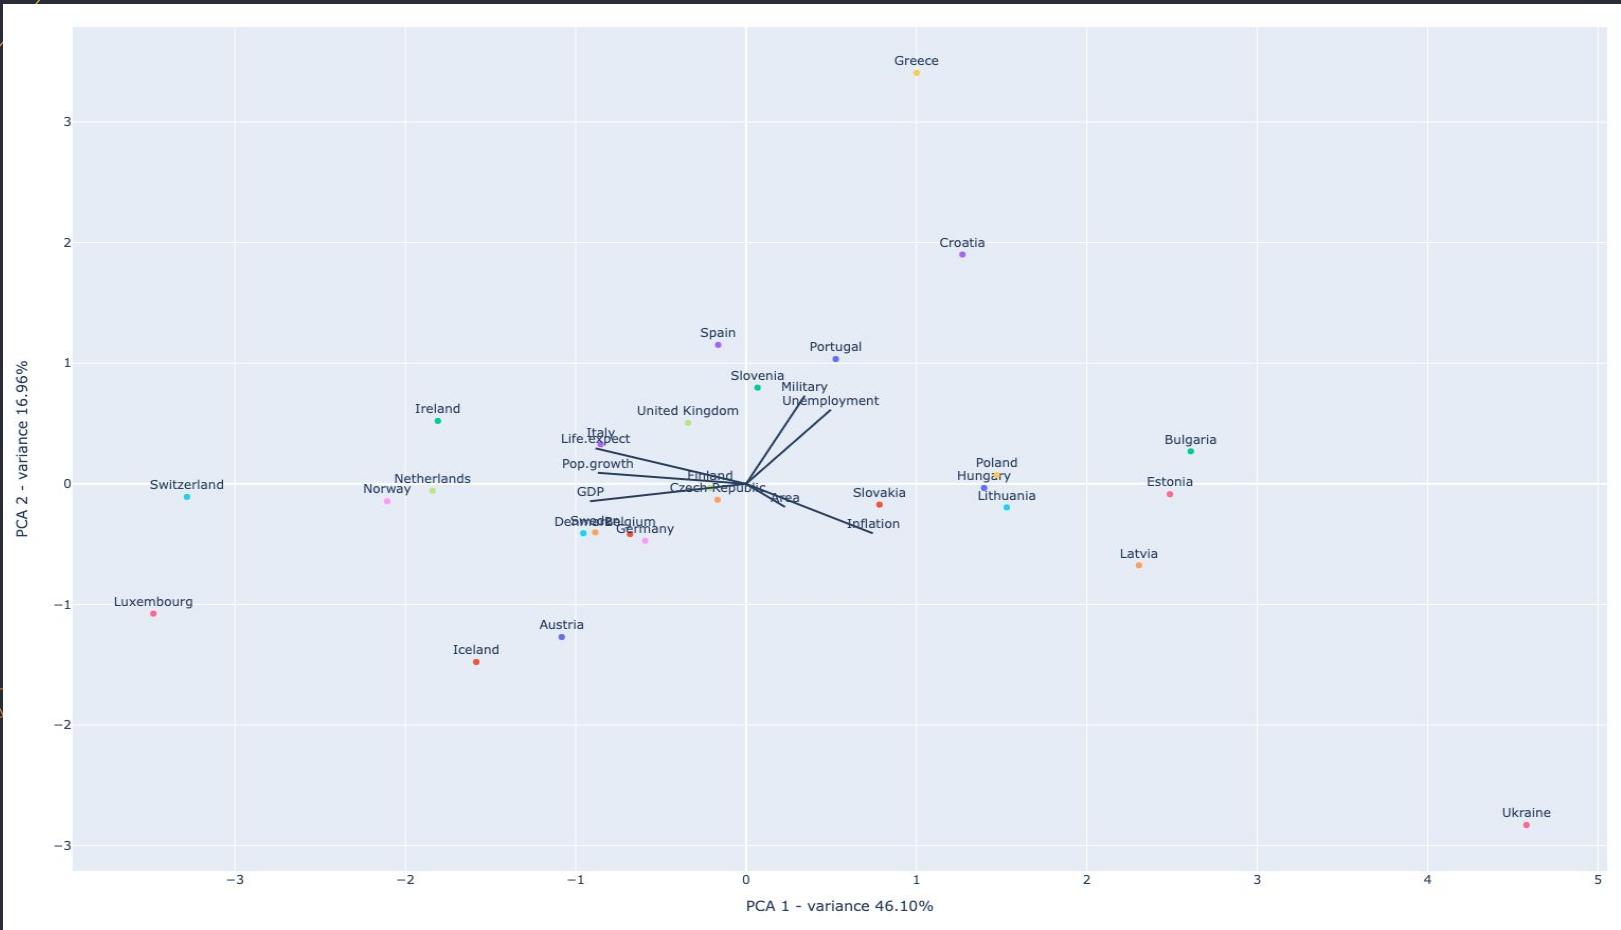
ASOCIACIÓN DE PAISES

- Utilizar la Red de Kohonen para asociar países que posean las mismas características geopolíticas, económicas y sociales.



ASOCIACIÓN DE PAISES

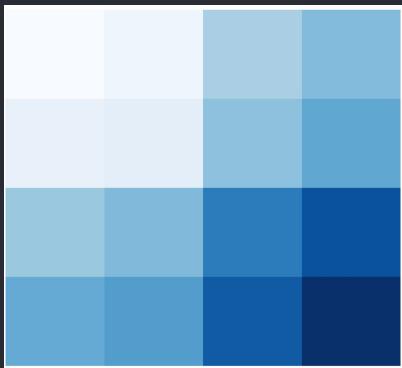




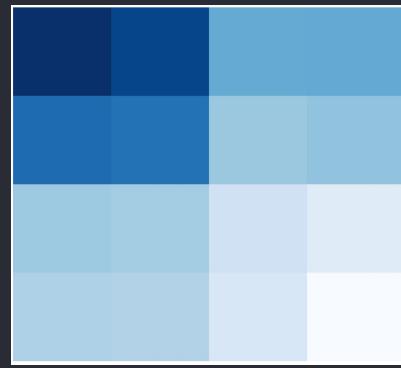
COMPONENTE POR NEURONA



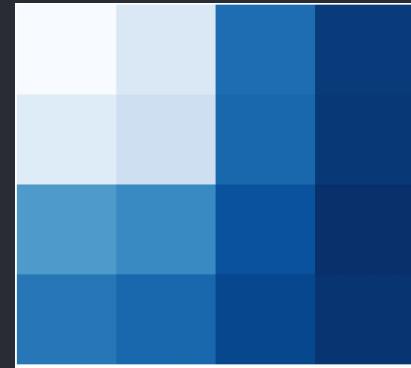
Area



GDP



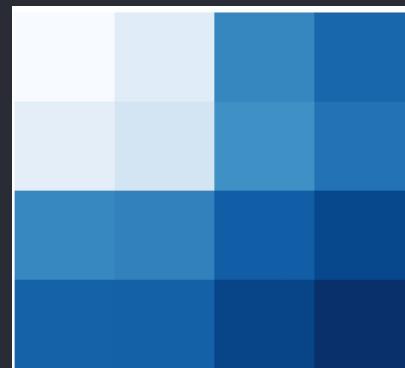
Inflation



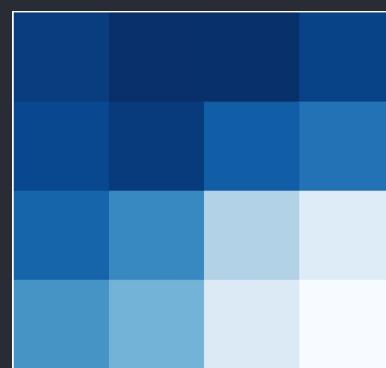
Life.expect



Military



Pop.growth



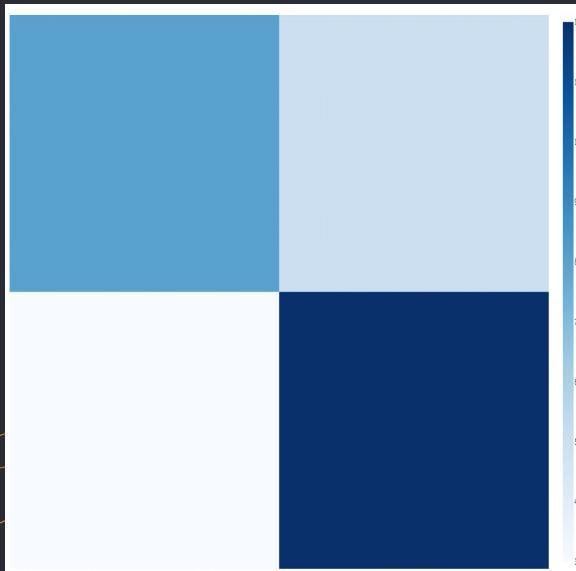
Unemployment

DISTANCIA PROMEDIO ENTRE NEURONAS VECINAS

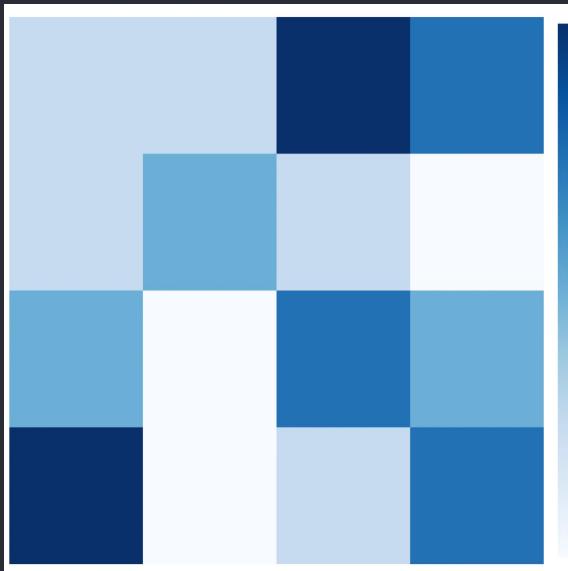


TAMAÑO DE GRILLA

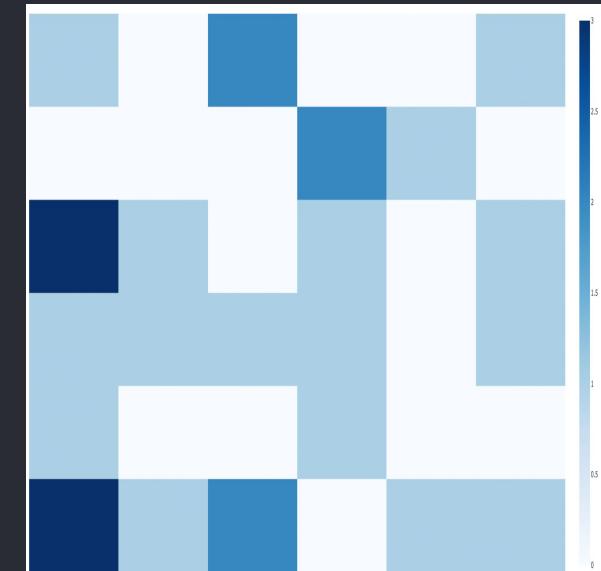
CANTIDAD DE PAÍSES POR NEURONA



2x2



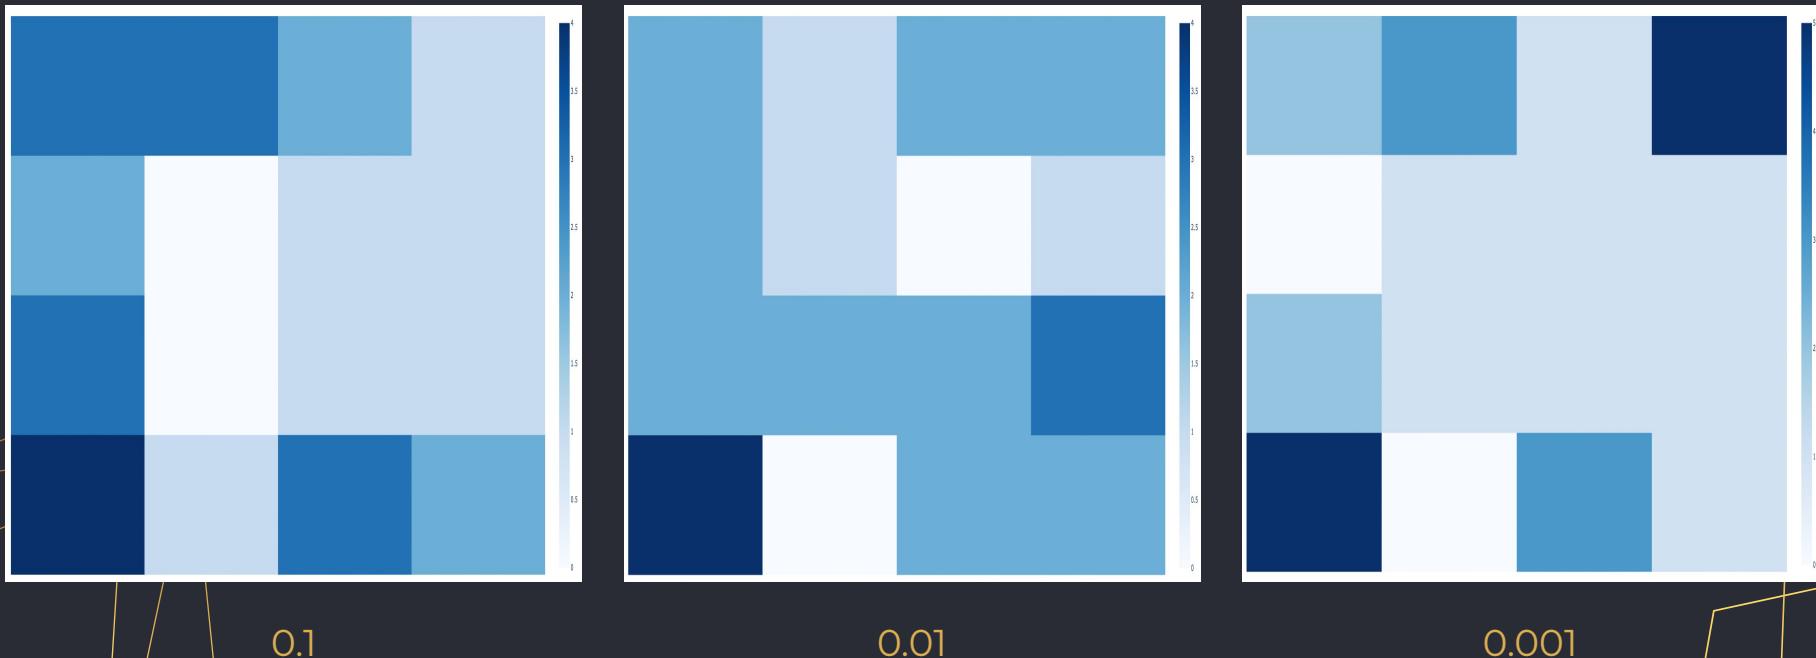
4x4



6x6

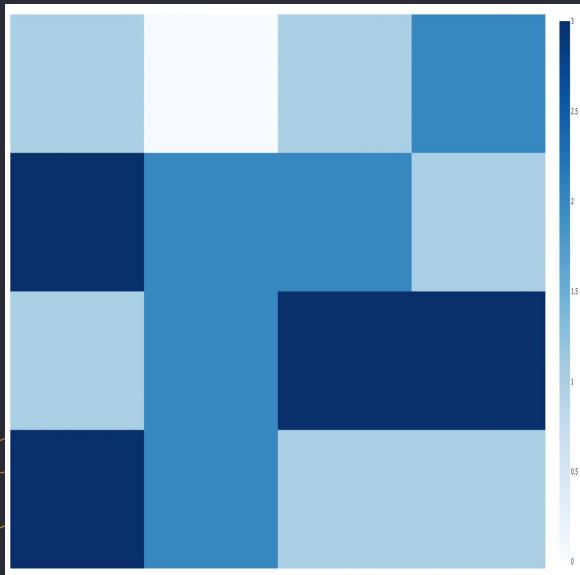
TASA DE APRENDIZAJE

CANTIDAD DE PAÍSES POR NEURONA

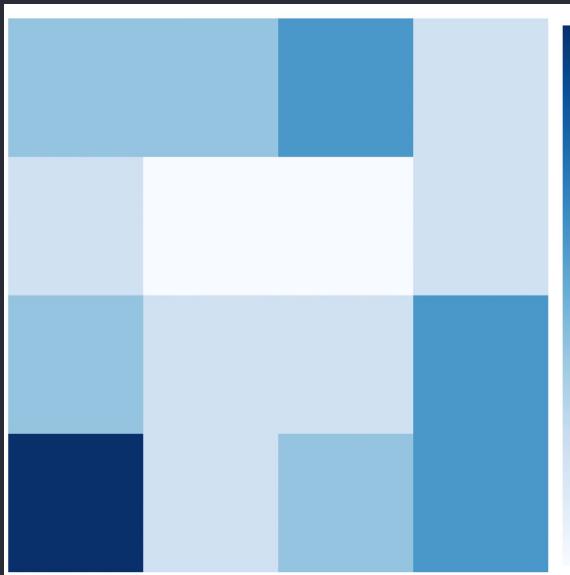


CANTIDAD DE ÉPOCAS

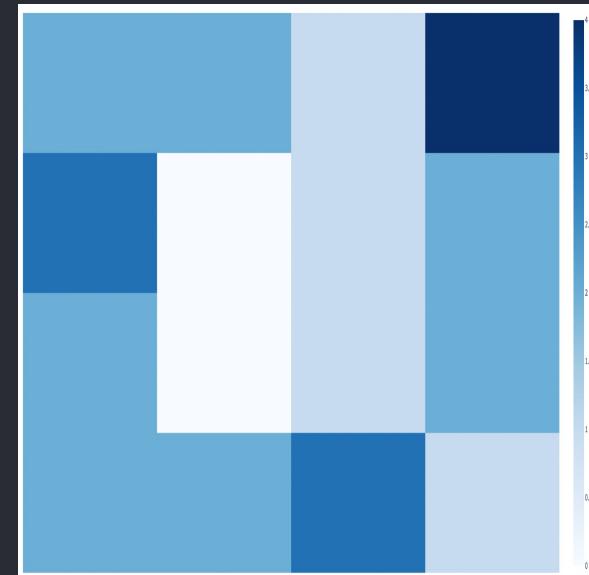
CANTIDAD DE PAÍSES POR NEURONA



100



1000



10000

CONCLUSIONES

- Consigue agrupar correctamente países con características similares.
- Buena alternativa al cálculo de componentes principales.
- Analizando componente a componente de los pesos se puede obtener información de los países.
- Difícil elegir un tamaño de grilla general, depende del problema.
- Para el problema, un tamaño grande de grilla implica una mayor cantidad de neuronas muertas.
 - A menor tasa de aprendizaje, los países quedan más agrupados.
 - A menor cantidad de épocas, los países quedan menos distribuidos.

REGLA OJA



EJERCICIO

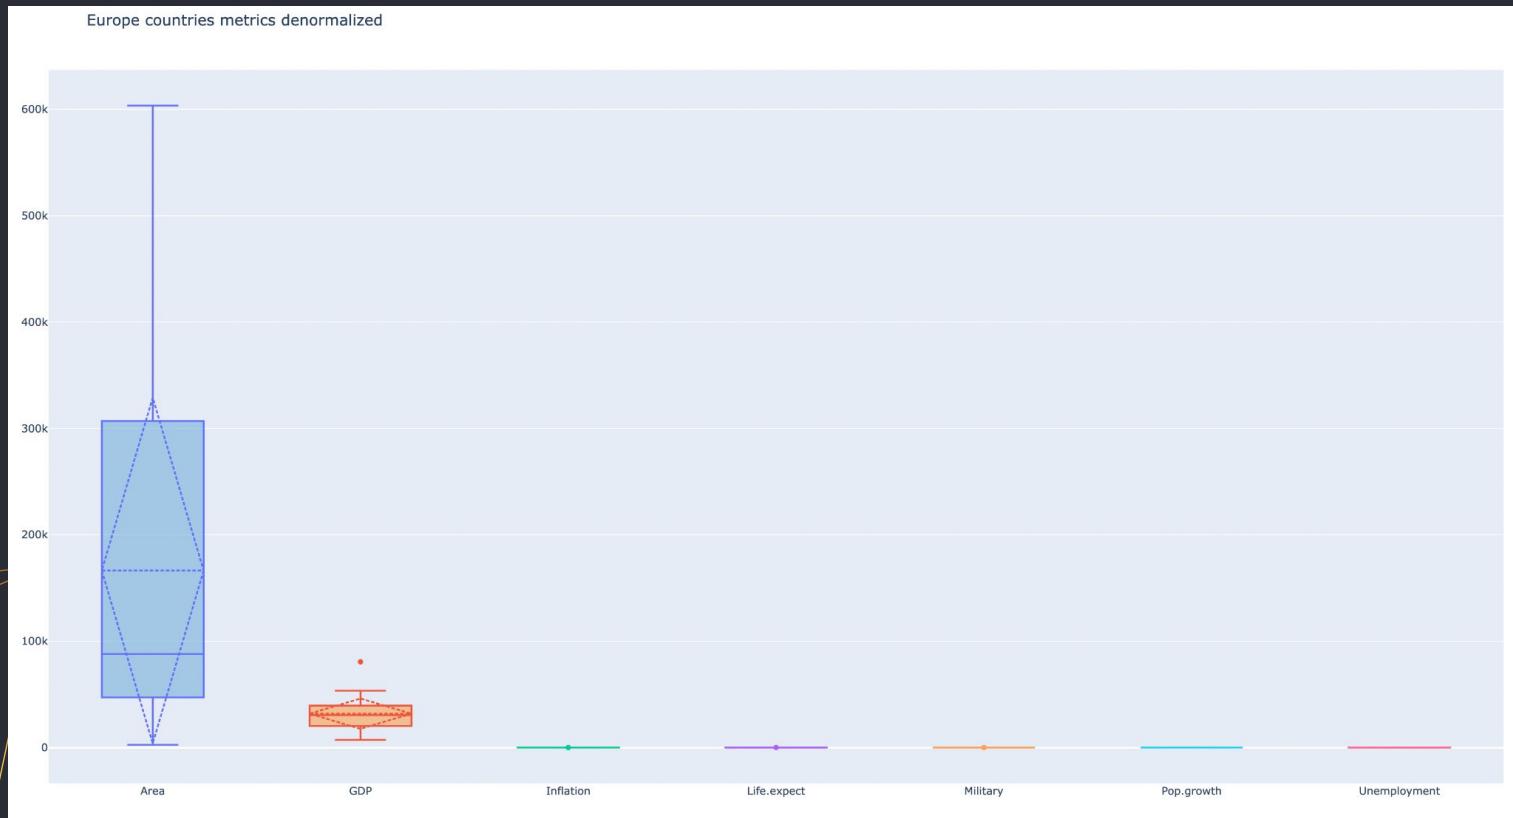
- A partir del mismo conjunto de datos de países europeos utilizar la regla de Oja para:
 1. Calcular la primera componente principal.
 2. Interpretar el resultado del primer componente.
 3. Comparar la primera componente principal con una calculada utilizando una librería.
- Consideraciones:

➤ Se estandarizó la información de los países.

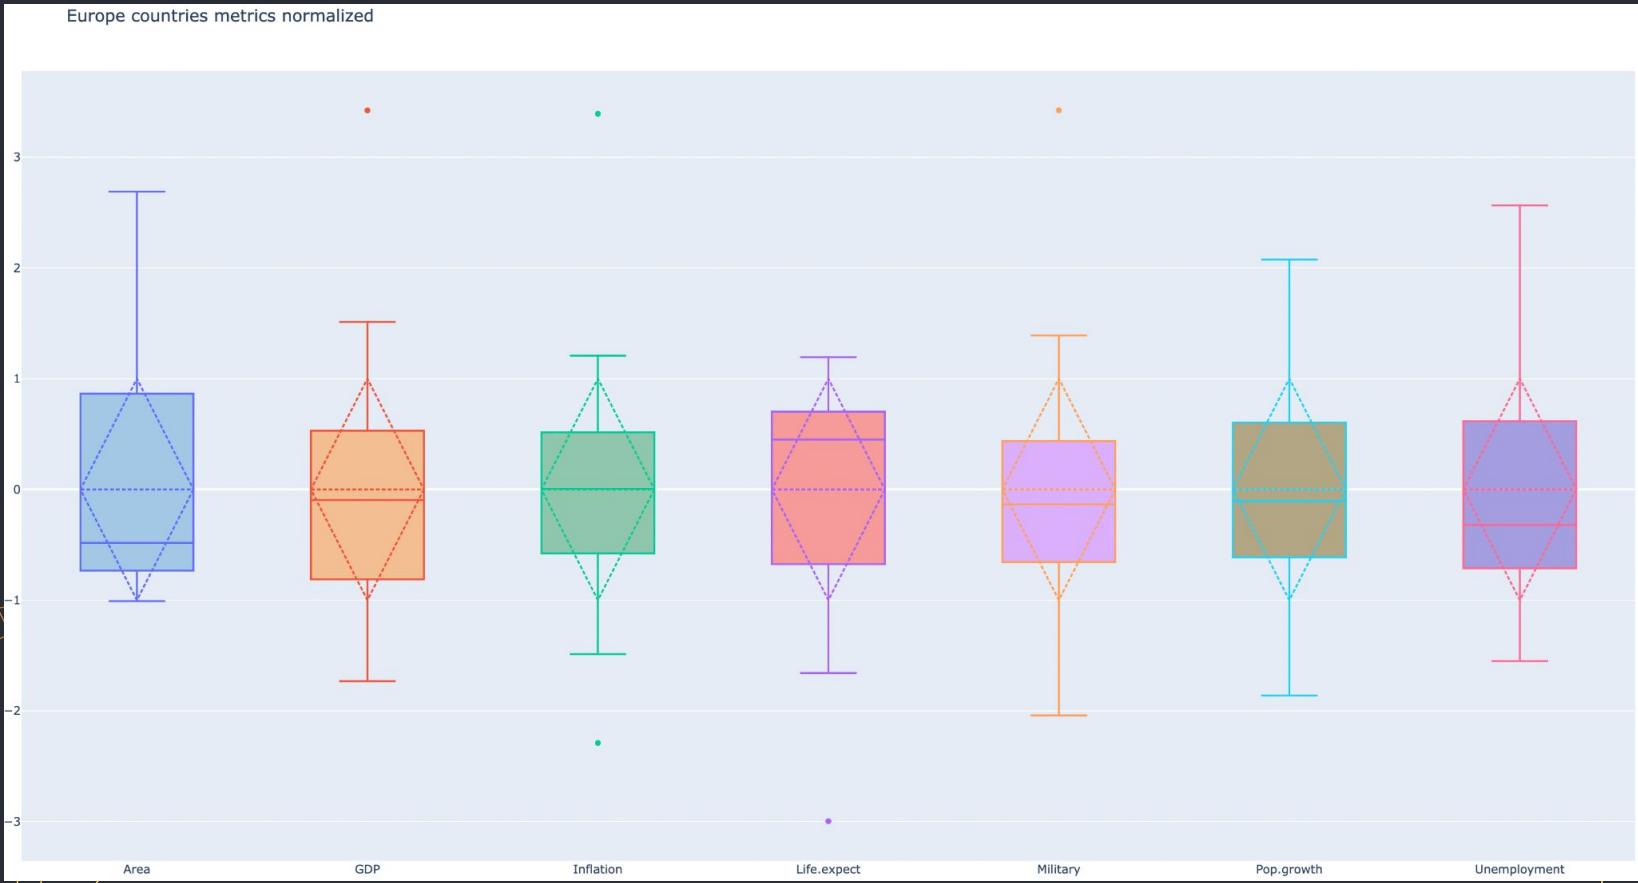
$$\tilde{X}_i = \frac{X_i - \bar{X}_i}{s}$$

➤ Cálculo de PCA exacto con la librería Sklearn.

DATOS DESNORMALIZADOS



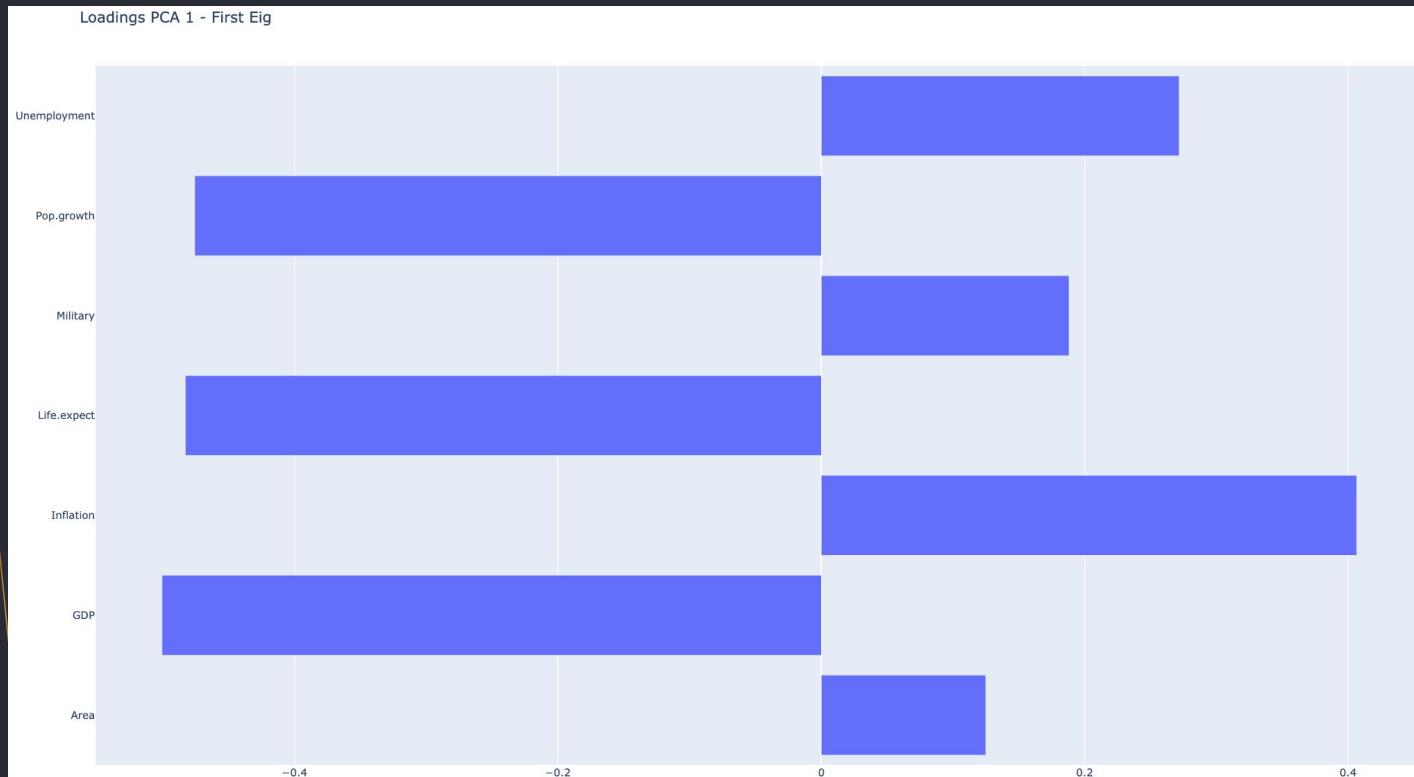
DATOS DESNORMALIZADOS



CARGAS PRIMER COMPONENTE - OJA



CARGAS PRIMER COMPONENTE - SKLEARN



COMPARACIÓN CARGAS - SKLEARN/OJA

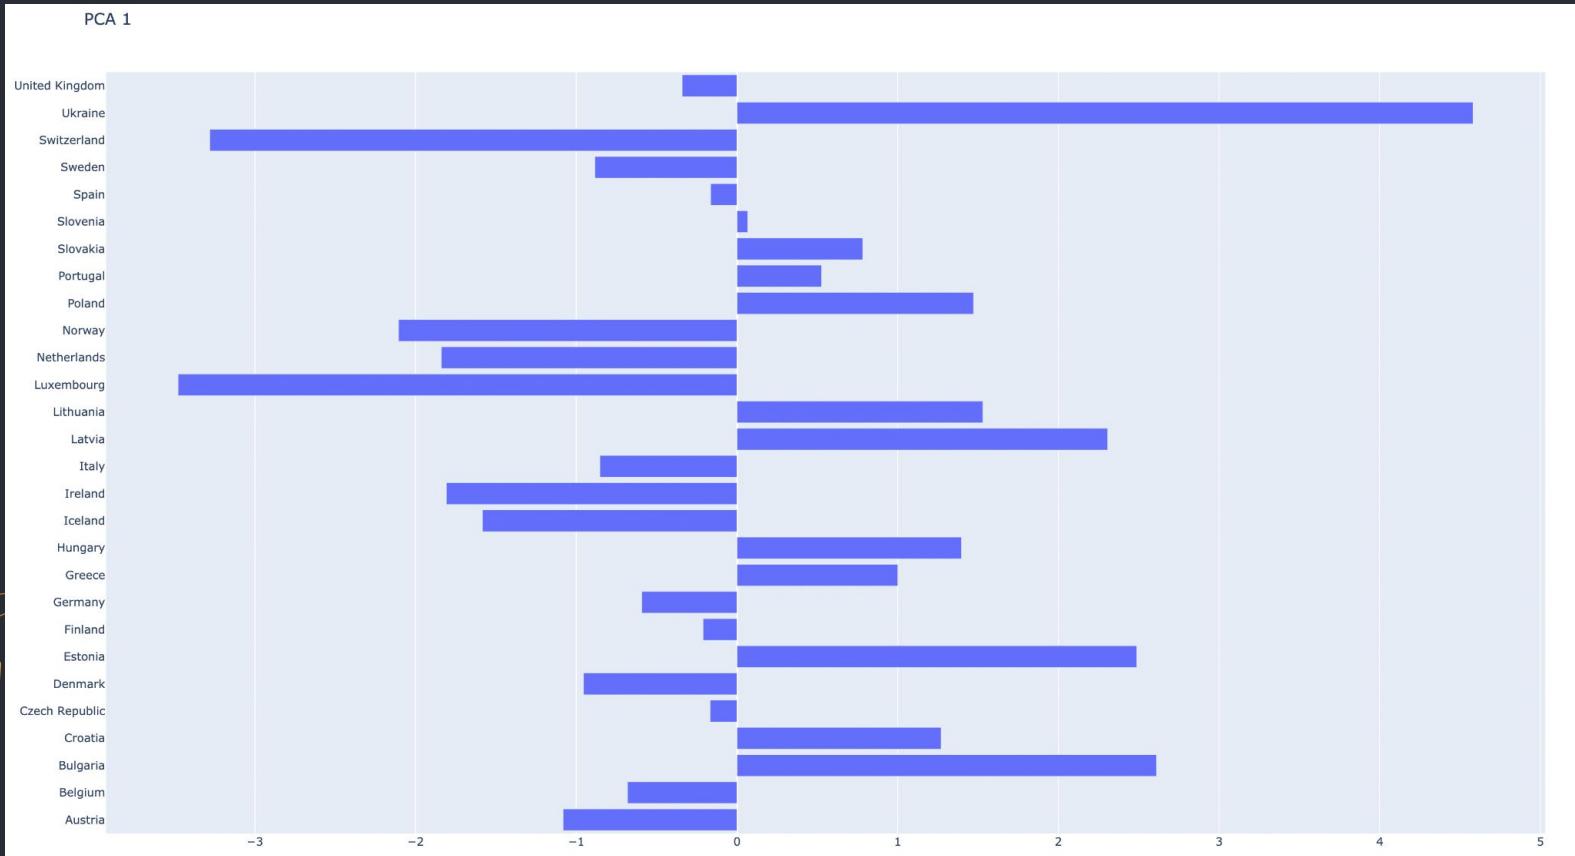
	Area	GDP	Inflation	Life.expect	Military	Pop.growth	Unemployment
EIG 1	0.1249	-0.5005	0.4065	-0.4829	0.1881	-0.4757	0.2717
EIG 1 Approx	0.1256	-0.5004	0.4072	-0.4830	0.1875	-0.4756	0.2713



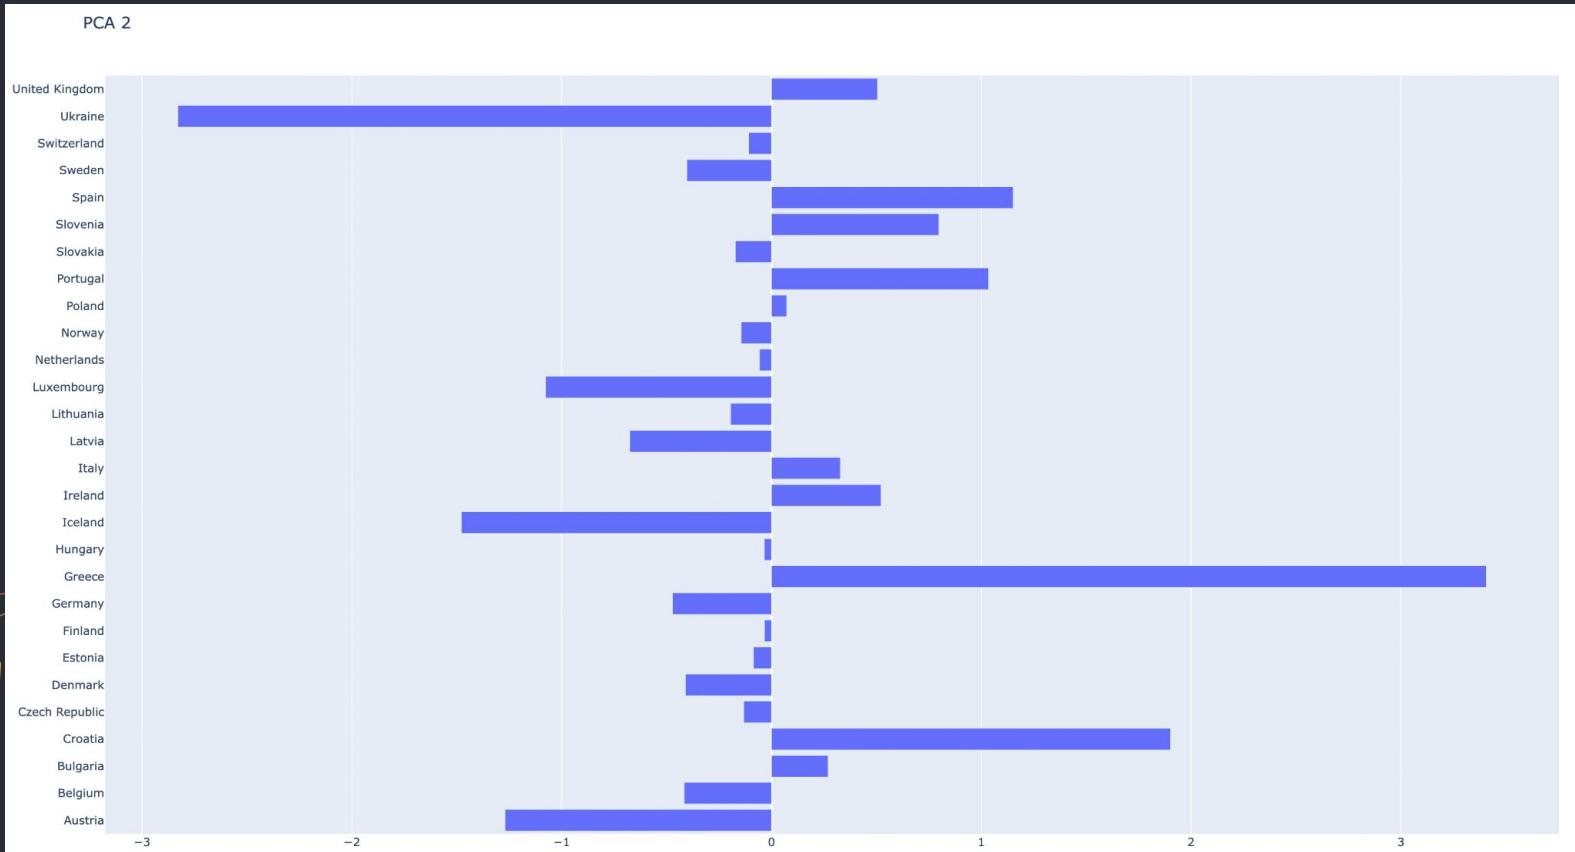
PRIMER COMPONENTE - OJA



PRIMER COMPONENTE - SKLEARN



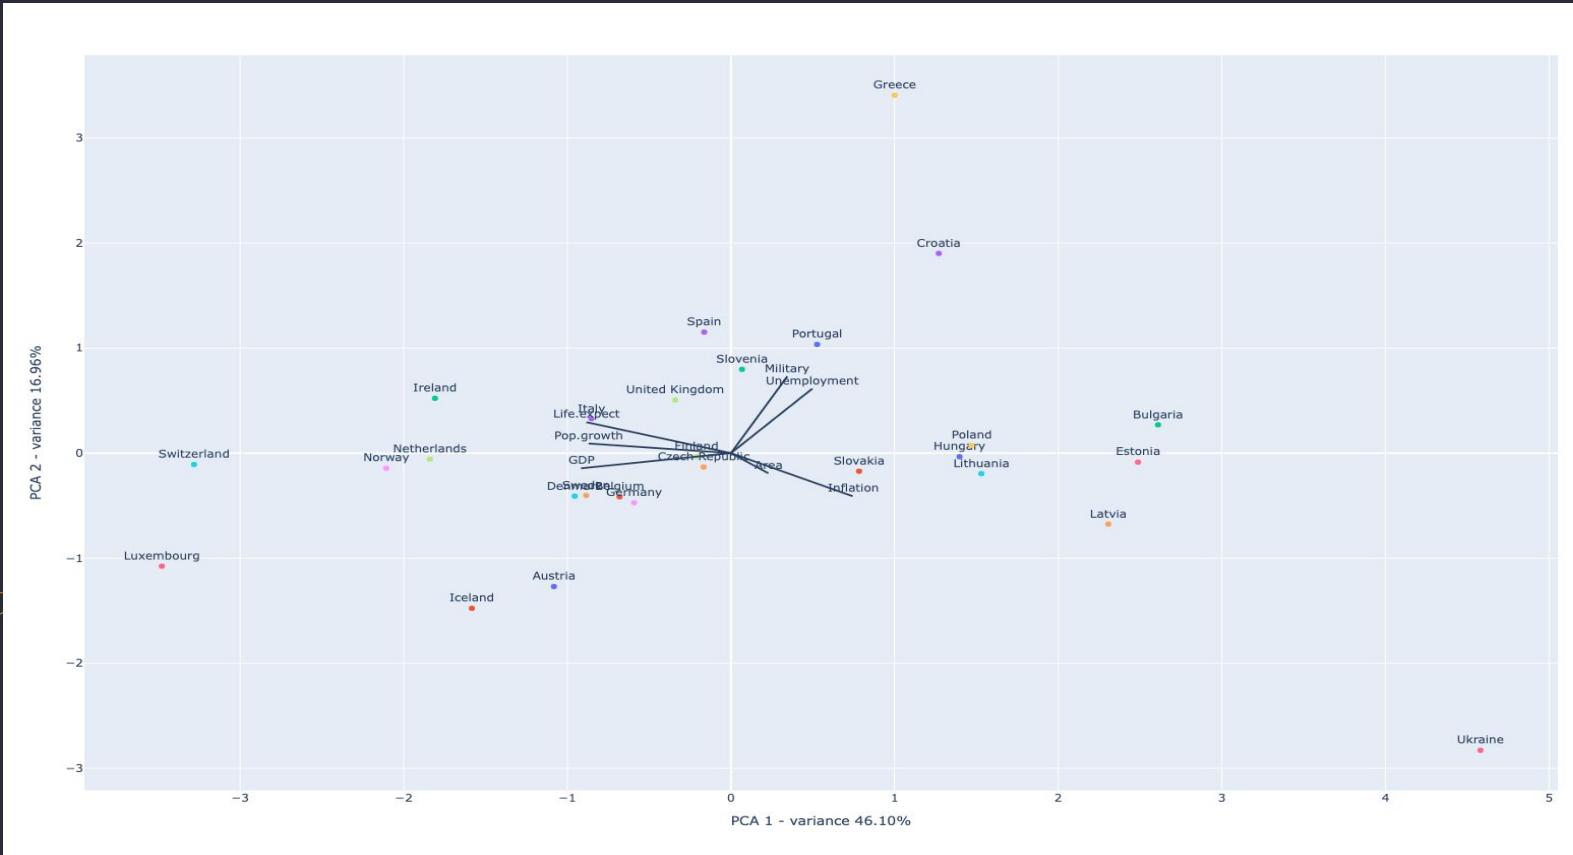
SEGUNDA COMPONENTE - SKLEARN



COMPARACIÓN PCA - SKLEARN/OJA

	PCA 1	PCA 1 Approx
Austria	-1.0817	-1.0811
Belgium	-0.6811	-0.6812
Bulgaria	2.6099	2.6092
Croatia	1.2701	1.2679
Czech Republic	-0.1672	-0.1679
Denmark	-0.9552	-0.9555
Estonia	2.4877	2.4875
Finland	-0.2106	-0.2100
Germany	-0.5924	-0.5918
Greece	1.0005	0.9976
Hungary	1.3969	1.3967
Iceland	-1.5837	-1.5822
Ireland	-1.8089	-1.8093
Italy	-0.8532	-0.8530
Latvia	2.3061	2.3063
Lithuania	1.5301	1.5301
Luxembourg	-3.4784	-3.4778
Netherlands	-1.8401	-1.8407
Norway	-2.1065	-2.1065
Poland	1.4718	1.4724
Portugal	0.5265	0.5256
Slovakia	0.7830	0.7829
Slovenia	0.0675	0.0658
Spain	-0.1638	-0.1630
Sweden	-0.8851	-0.8839
Switzerland	-3.2816	-3.2826
Ukraine	4.5803	4.5850
United Kingdom	-0.3408	-0.3405

BI PLOT - SKLEARN



CONCLUSIONES

- Importante estandarizar los datos.
- La regla de Oja consigue aproximar correctamente el autovector asociado al mayor autovalor de la matriz de correlación.
- Con tasas de aprendizaje bajas, el error es muy grande.
- La primer componente separa las características en dos grupos:
 - Crecimiento poblacional, expectativa de vida y PBI.
 - Desempleo, inflación, nivel militar y área.
- Países que se encuentran mejor económica y socialmente tienen mayor peso en las componentes del primer grupo. En contraparte, los que se encuentran en peores condiciones tienen mayor peso del segundo grupo.

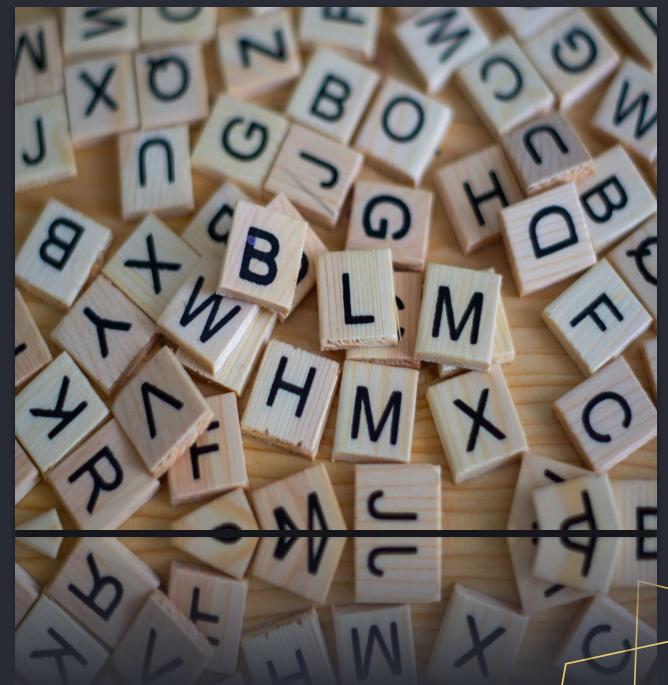
MODELO DE HOPFIELD



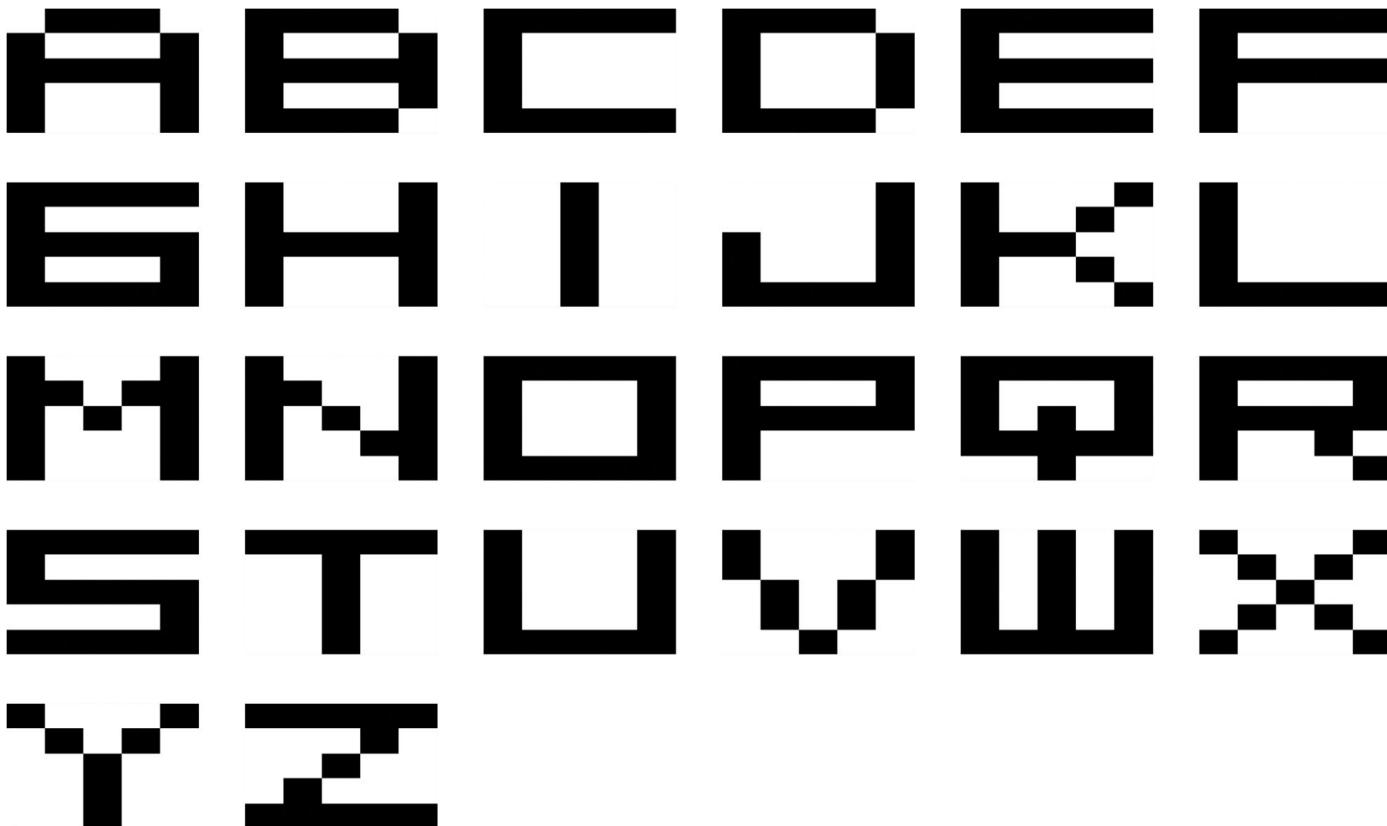
EJERCICIO

Construir patrones de letras del abecedario utilizando 1 y -1 en matrices de 5x5.

- Almacenar 4 patrones de letras y realizar un programa que utilice el modelo de Hopfield para asociar matrices ruidosas de 5x5 con los patrones de las letras almacenadas.
- Los patrones de consulta deben ser alteraciones aleatorias de los patrones originales.



FUENTE



LIMITACIONES

- Patrones de 25 elementos.
- La red sólo podrá almacenar una cantidad de patrones equivalente al 15% del tamaño de un patrón:
 - $15\% \text{ de } 25 = 3.75 \approx 4$
- Los patrones no serán 100% ortogonales ya que la cantidad de elementos en cada uno es impar.

PATRONES MÁS ORTOGONALES

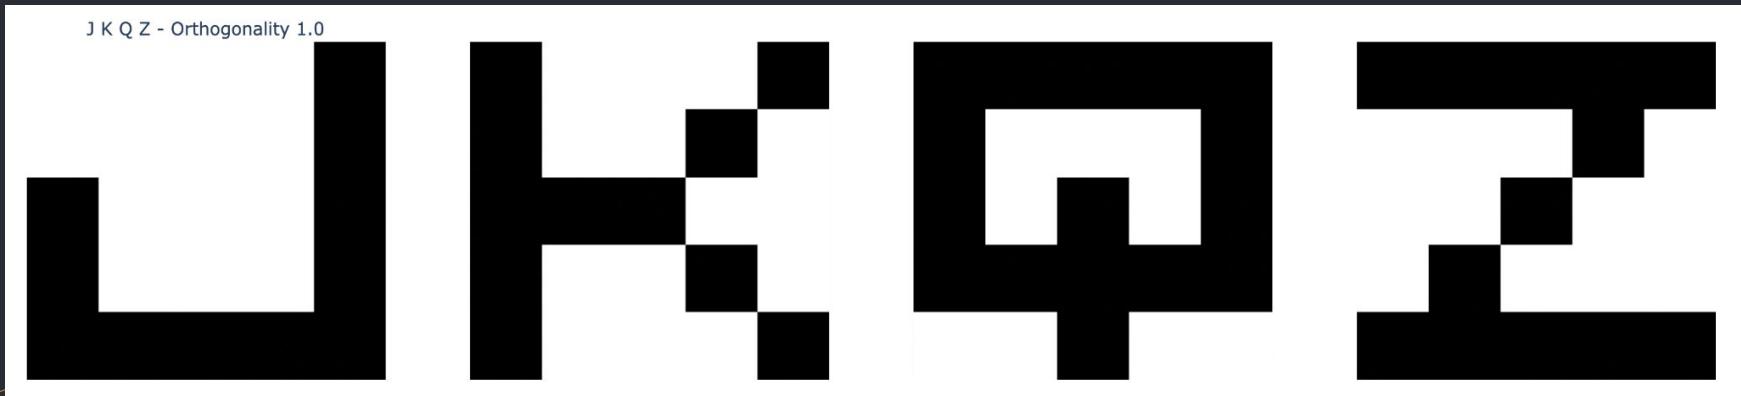
Combination	Orthogonality	Max Orthogonality
J K Q Z	1.0000	1
F I L V	1.3333	3
F I W Z	1.3333	3
F U V Z	1.3333	3
I J Q Z	1.3333	3
I K Q Z	1.3333	3
I K W Z	1.3333	3
L R T X	1.3333	3
F I L X	1.6667	3
F I V Z	1.6667	3
I J K Q	1.6667	3
I J K Z	1.6667	3
I Q V Z	1.6667	3
L R T V	1.6667	3
I L V X	1.6667	5
F I J Z	2.0000	3
F J V Z	2.0000	3
I J Q V	2.0000	3
I J V Z	2.0000	3
J P V Z	2.0000	3

PATRONES MENOS ORTOGONALES

Combination	Orthogonality	Max Orthogonality
B F P R	17.0000	23
C G O S	17.0000	23
D E G S	17.0000	23
E F G R	17.0000	23
B D G O	17.3333	21
B E F G	17.3333	23
F G P R	17.3333	23
B E G O	17.6667	23
B G O S	17.6667	23
C E G O	17.6667	23
E F G P	17.6667	23
E G P S	17.6667	23
E G R S	17.6667	23
F H P R	17.6667	23
E F P R	18.3333	23
A F P R	18.6667	23
C E G S	18.6667	23
E F G S	18.6667	23
E G O S	19.0000	23
B E G S	20.0000	23

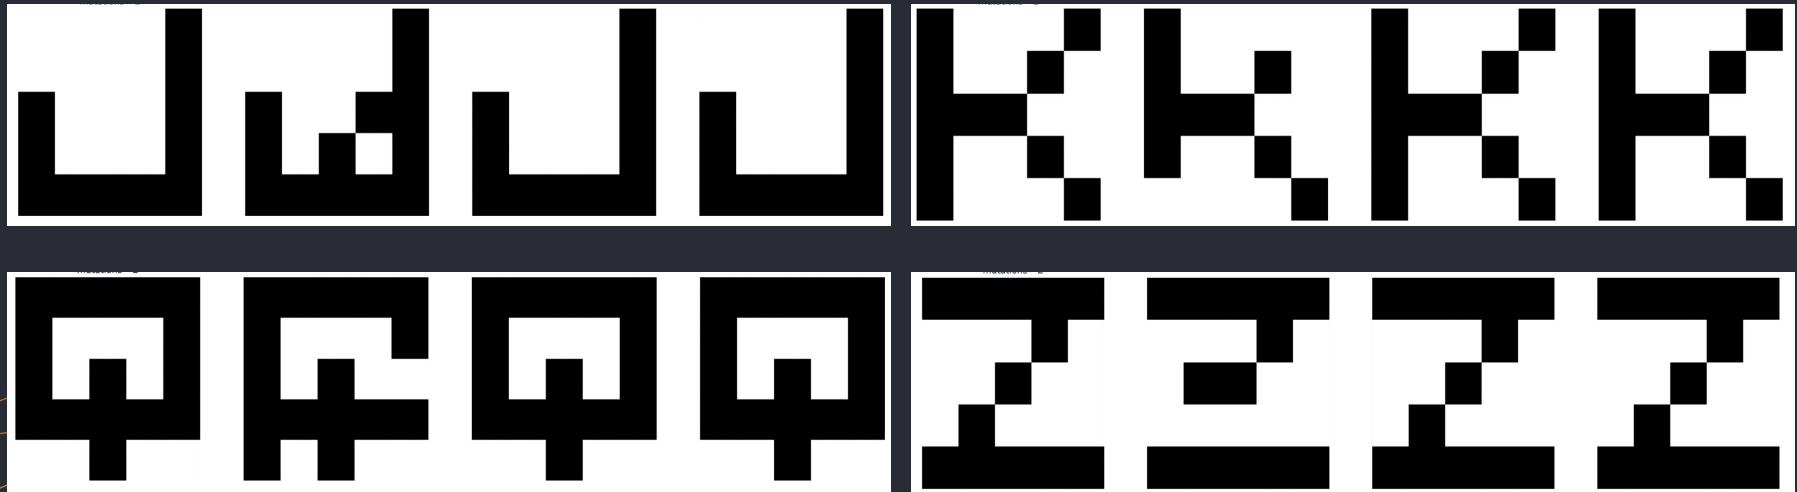
ASOCIACIÓN DE PATRONES MUY ORTOGONALES

J K Q Z - Orthogonality 1.0



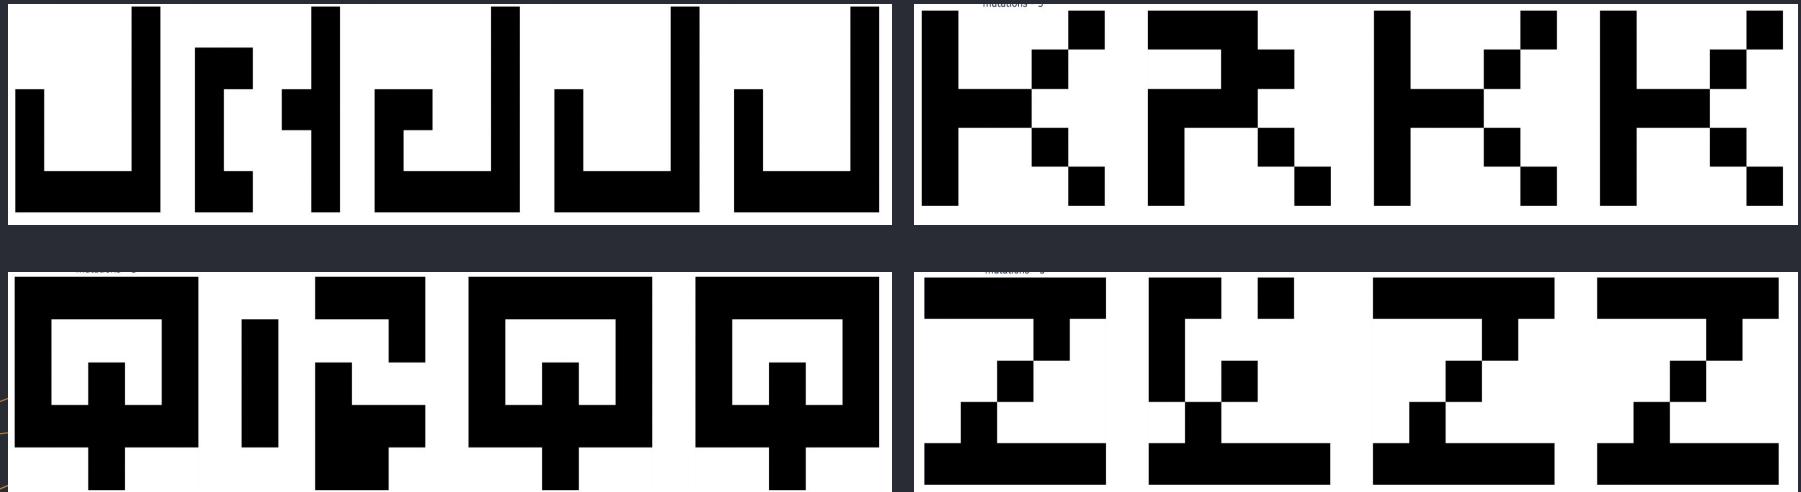
ASOCIACIÓN DE PATRONES MUY ORTOGONALES

2 MUTACIONES



ASOCIACIÓN DE PATRONES MUY ORTOGONALES

5 MUTACIONES

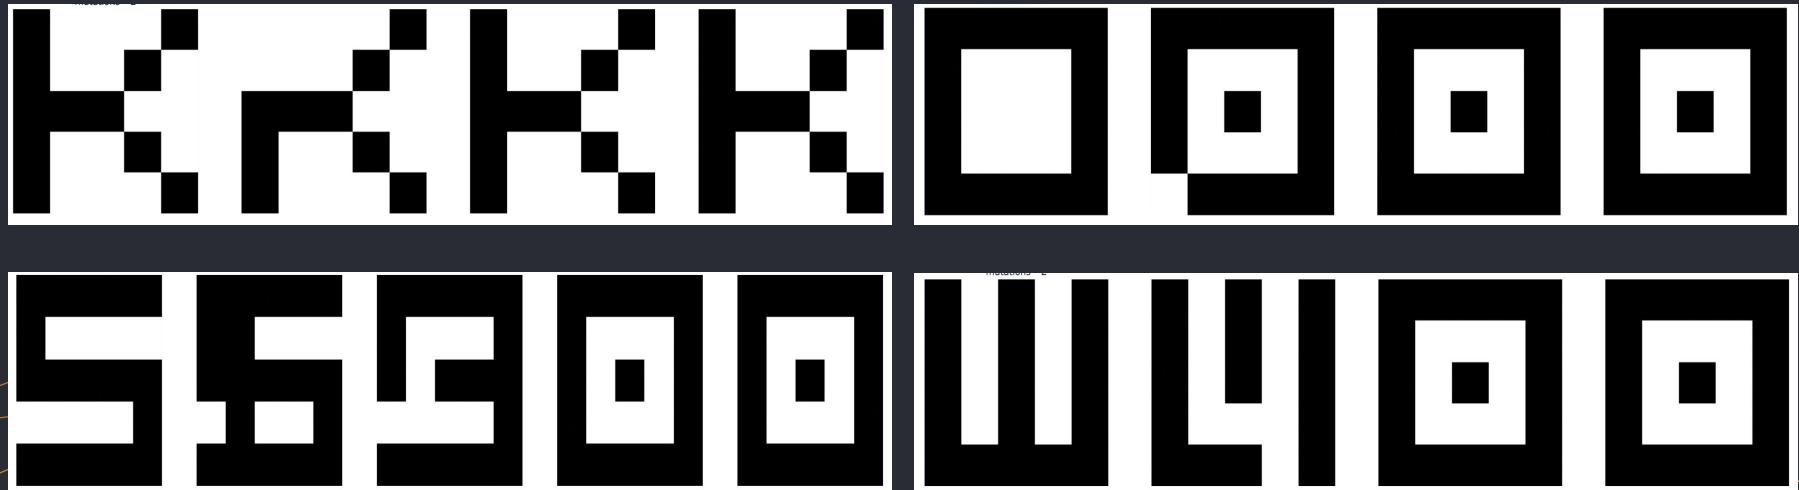


ASOCIACIÓN DE PATRONES MEDIO ORTOGONALES



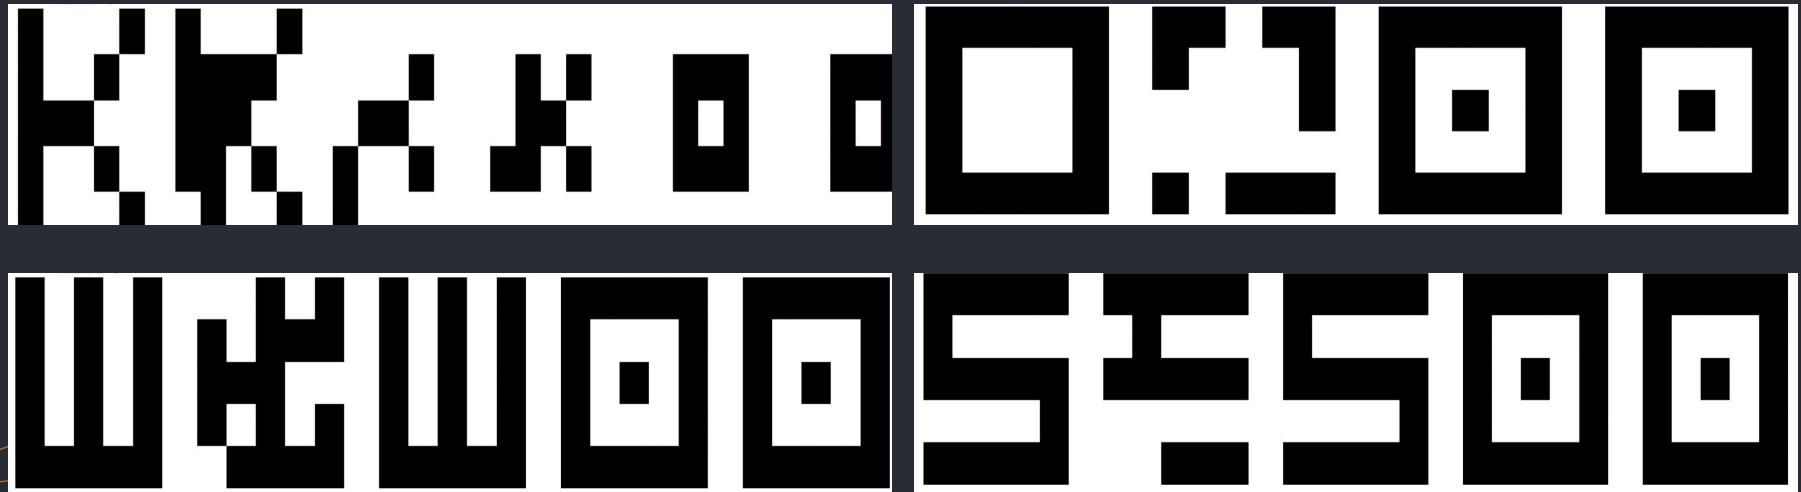
ASOCIACIÓN DE PATRONES MEDIO ORTOGONALES

2 MUTACIONES



ASOCIACIÓN DE PATRONES MEDIO ORTOGONALES

5 MUTACIONES

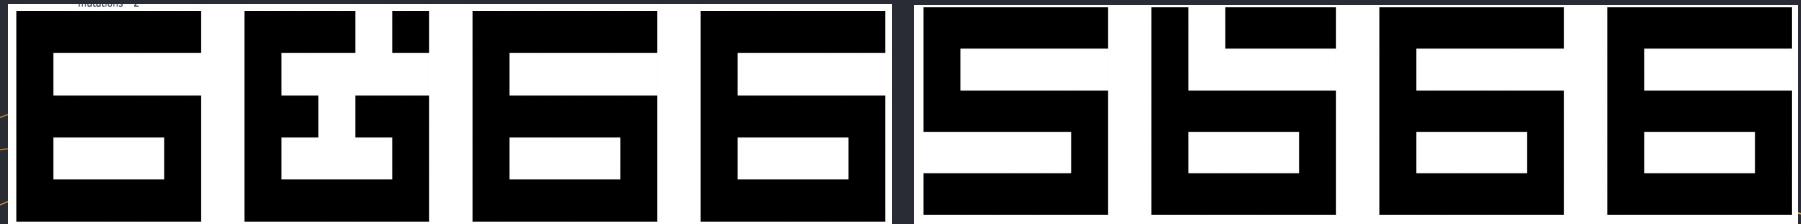


ASOCIACIÓN DE PATRONES POCO ORTOGONALES



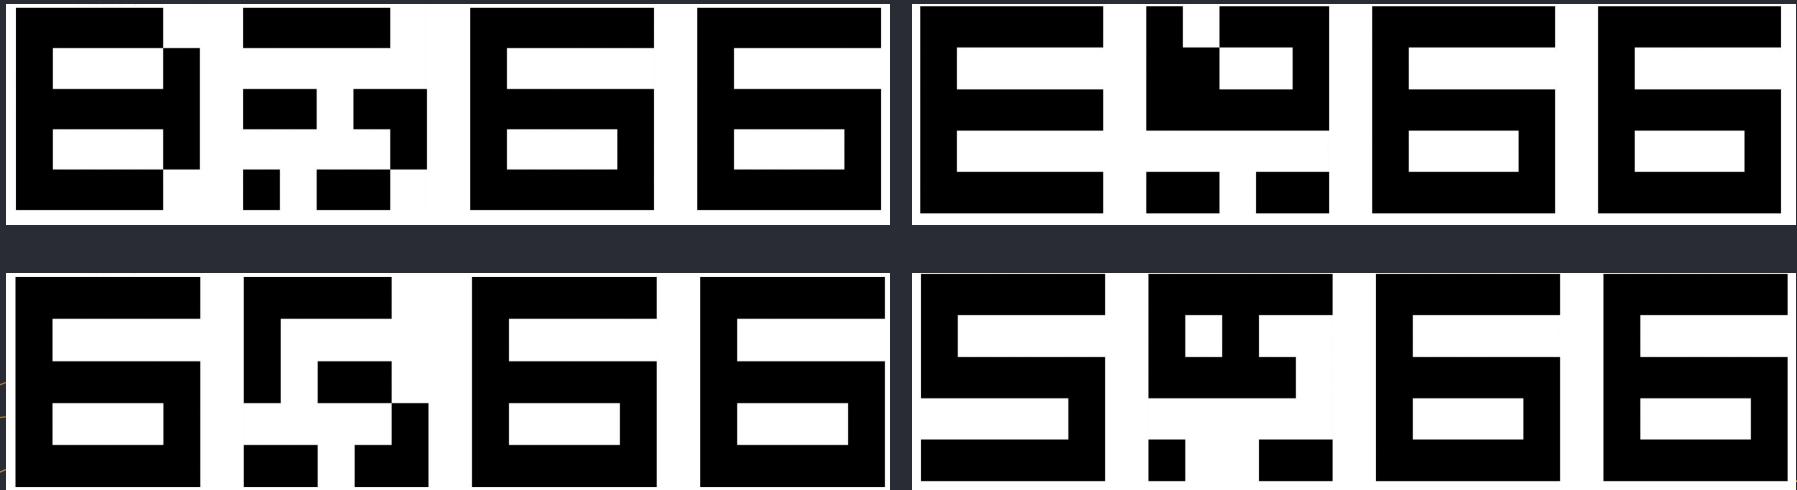
ASOCIACIÓN DE PATRONES POCO ORTOGONALES

2 MUTACIONES



ASOCIACIÓN DE PATRONES POCO ORTOGONALES

5 MUTACIONES

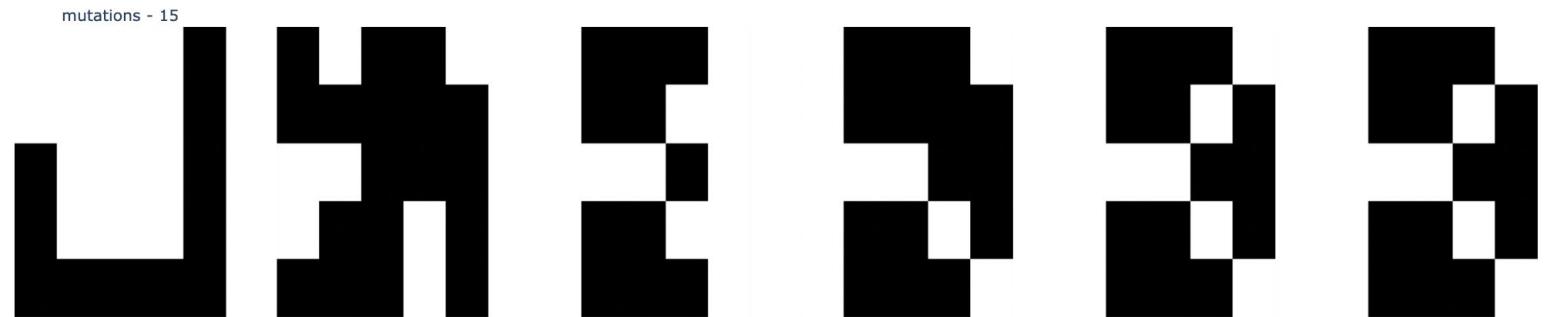


ESTADO ESPÚREO

J K Q Z - Orthogonality 1.0

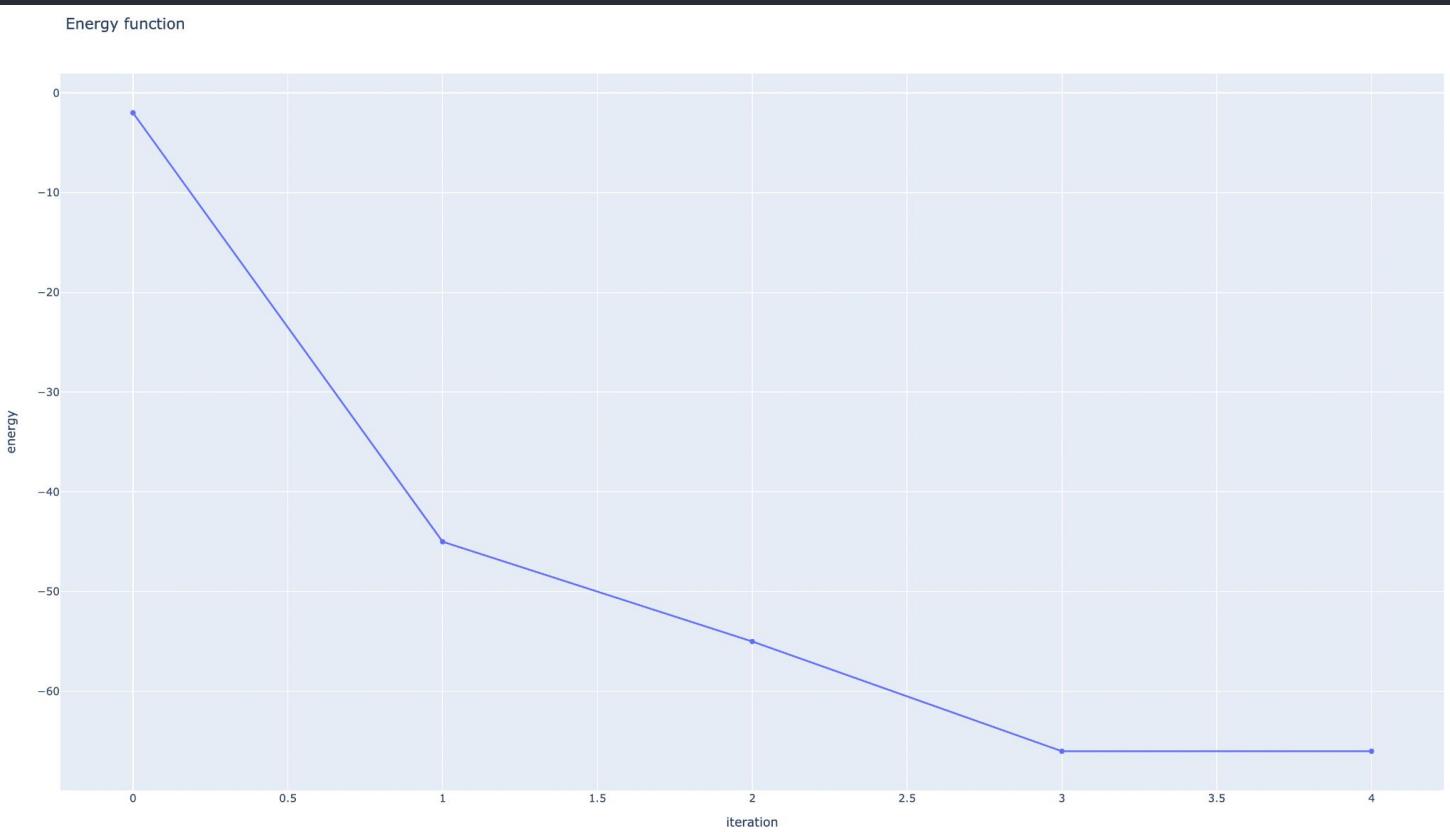


mutations - 15



ESTADO ESPÚREO

FUNCTION DE ENERGIA



CONCLUSIONES

- Cuanto más ortogonales sean los patrones, mejor asocia patrones ruidosos.
- Patrones más parecidos son menos ortogonales.
- Depende cómo se genera el ruido, aunque los patrones sean bastante ortogonales, se puede converger a un estado espurio.
- Se debe almacenar únicamente un 15% de la dimensión del patrón.
- A mayor ruido, mayor probabilidad de caer en un estado espúreo, aun con patrones muy ortogonales.
- La función de energía asociada siempre decrece.

MUCHAS GRACIAS